

Laboratorio 5

En este laboratorio, estaremos repasando los conceptos de Atención y Transformadores. Buscaremos acercarnos a la implementación del paper "[Attention is All you Need](#)". Por ello, todas las imágenes que veremos acá son del paper, a menos que se indique lo contrario.

Al igual que en laboratorios anteriores, para este laboratorio estaremos usando una herramienta para Jupyter Notebooks que facilitará la calificación, no solo asegurando que ustedes tengan una nota pronto sino también mostrándoles su nota final al terminar el laboratorio.

De nuevo me discupo si algo no sale bien, seguiremos mejorando conforme vayamos iterando. Siempre pido su comprensión y colaboración si algo no funciona como debería.

Al igual que en el laboratorio pasado, estaremos usando la librería de Dr John Williamson et al de la University of Glasgow, además de ciertas piezas de código de Dr Bjorn Jensen de su curso de Introduction to Data Science and System de la University of Glasgow para la visualización de sus calificaciones.

NOTA: Ahora también hay una tercera dependencia que se necesita instalar. Ver la celda de abajo por favor

In []:

```
# Una vez instalada la librería por favor, recuerden volverla a comentar.
```

In [1]:

```
!pip install -U --force-reinstall --no-cache https://github.com/johnhw/jhwutils/zipball/master
```

```
Collecting https://github.com/johnhw/jhwutils/zipball/master
  Downloading https://github.com/johnhw/jhwutils/zipball/master
    - 38.1 kB 556.6 kB/s 0:00:00
  Preparing metadata (setup.py) ... done
Building wheels for collected packages: jhwutils
  Building wheel for jhwutils (setup.py) ... done
  Created wheel for jhwutils: filename=jhwutils-1.0-py3-none-any.whl size=33801 sha256=3c622ec7ebd843bb31c3fda7c96239db00d0792d20cbbc3b5f42f33dd0a923d
  Stored in directory: /private/var/folders/h4/rlgjjv6s50z2sflx2_9bt49h0000gn/T/pip-ephem-wheel-cache-_dl1f0wo/wheels/27/3c/cb/eb7b3c6ea36b5b54e5746751443be9bb0d73352919033558a2
Successfully built jhwutils
Installing collected packages: jhwutils
  Attempting uninstall: jhwutils
    Found existing installation: jhwutils 1.0
    Uninstalling jhwutils-1.0:
      Successfully uninstalled jhwutils-1.0
Successfully installed jhwutils-1.0
```

In [2]:

```
!pip install scikit-image
```

```
Requirement already satisfied: scikit-image in /Users/fredyvelasquez/anaconda3/lib/python3.10/site-packages (0.19.3)
Requirement already satisfied: numpy>=1.17.0 in /Users/fredyvelasquez/anaconda3/lib/python3.10/site-packages (from scikit-image) (1.23.5)
Requirement already satisfied: pillow!=7.1.0,!=7.1.1,!=8.3.0,>=6.1.0 in /Users/fredyvelasquez/anaconda3/lib/python3.10/site-packages (from scikit-image) (9.4.0)
Requirement already satisfied: PyWavelets>=1.1.1 in /Users/fredyvelasquez/anaconda3/lib/python3.10/site-packages (from scikit-image) (1.4.1)
Requirement already satisfied: imageio>=2.4.1 in /Users/fredyvelasquez/anaconda3/lib/python3.10/site-packages (from scikit-image) (2.26.0)
Requirement already satisfied: networkx>=2.2 in /Users/fredyvelasquez/anaconda3/lib/python3.10/site-packages (from scikit-image) (2.8.4)
Requirement already satisfied: tifffile>=2019.7.26 in /Users/fredyvelasquez/anaconda3/lib/python3.10/site-packages (from scikit-image) (2021.7.2)
Requirement already satisfied: scipy>=1.4.1 in /Users/fredyvelasquez/anaconda3/lib/python3.10/site-packages (from scikit-image) (1.10.0)
```

Requirement already satisfied: packaging>=20.0 in /Users/fredyvelasquez/anaconda3/lib/python3.10/site-packages (from scikit-image) (22.0)

In [3]:

```
!pip install -U --force-reinstall --no-cache https://github.com/AlbertS789/lautils/zipball/master
```

```
Collecting https://github.com/AlbertS789/lautils/zipball/master
  Downloading https://github.com/AlbertS789/lautils/zipball/master
    - 4.2 kB 3.7 MB/s 0:00:00
  Preparing metadata (setup.py) ... done
Building wheels for collected packages: lautils
  Building wheel for lautils (setup.py) ... done
  Created wheel for lautils: filename=lautils-1.0-py3-none-any.whl size=2825 sha256=4015b0e578774838db16c27b978efe7d9b8f726cbfd7fbb3691433ac33035742
  Stored in directory: /private/var/folders/h4/rlgjjv6s50z2sflx2_9bt49h0000gn/T/pip-ephem-wheel-cache-oph7g917/wheels/16/3a/a0/5fbae86e17ef6bb8ed057aa04b591584005d1212c72d69fc70
Successfully built lautils
Installing collected packages: lautils
  Attempting uninstall: lautils
    Found existing installation: lautils 1.0
    Uninstalling lautils-1.0:
      Successfully uninstalled lautils-1.0
Successfully installed lautils-1.0
```

In [66]:

```
import numpy as np
import copy
import matplotlib.pyplot as plt
import scipy
from PIL import Image
import os
from collections import defaultdict

#from IPython import display
#from base64 import b64decode

# Other imports
from unittest.mock import patch
from uuid import getnode as get_mac

from jhwutils.checkarr import array_hash, check_hash, check_scalar, check_string, array_hash, _check_scalar
import jhwutils.image_audio as ia
import jhwutils.tick as tick
from lautils.gradeutils import new_representation, hex_to_float, compare_numbers, compare_lists_by_percentage, calculate_coincidences_percentage

###
tick.reset_marks()

%matplotlib inline
```

In [5]:

```
# Seeds
seed_ = 2023
np.random.seed(seed_)
```

In []:

```
# Celda escondida para utilidades necesarias, por favor NO edite esta celda
```

Información del estudiante en dos variables

- **carne_1** : un string con su carne (e.g. "12281"), debe ser de al menos 5 caracteres.
- **firma_mecanografiada_1**: un string con su nombre (e.g. "Albero Suriano") que se usará para la declaración

que este trabajo es propio (es decir, no hay plagio)

- `carne_2` : un string con su carne (e.g. "12281"), debe ser de al menos 5 caracteres.
- `firma_mecanografiada_2`: un string con su nombre (e.g. "Albero Suriano") que se usará para la declaracion que este trabajo es propio (es decir, no hay plagio)

In []:

```
carne_1 = "201011"
firma_mecanografiada_1 = "Fredy Velasquez"
carne_2 = "20460"
firma_mecanografiada_2 = "Angel Higueros"
# YOUR CODE HERE
```

In []:

```
# Deberia poder ver dos checkmarks verdes [0 marks], que indican que su información básica
a está OK

with tick.marks(0):
    assert (len(carne_1)>=5 and len(carne_2)>=5)

with tick.marks(0):
    assert (len(firma_mecanografiada_1)>0 and len(firma_mecanografiada_2)>0)
```

Introducción

Similar al modelo Seq2Seq, el modelo de Transformer no usará recurrencias, ni tampoco capas convolucionales. En su lugar, el modelo está hecho meramente con capas lineales, mecanismos de atención y normalización.

Una de las variantes más populares de los Transformadores es BERT (Bidirectional Encoder Representations from Transformers) y versiones pre-entrenadas de BERT que son comunmente usadas para sustituir capas de embedding (y otras cosas más) en modelos de NLP.

Cabe destacar algunas diferencias entre la implementación que haremos y la del paper:

- Usaremos un positional encoding aprendido y no uno estático
- Usaremos un optimizador estándar Adam con un learning rate estático, en lugar de uno con warm-up y cool-down
- No usaremos label smoothing

Se consideran estas modificaciones a finalidad de hacer una implementación que se acerque a como BERT suele ser seteado.

Consideren que para esta parte estaremos usando el mismo dataset que usamos para la segunda parte del laboratorio pasado. Por ende, sugiero que usen el mismo venv que usaron para esa parte.

Créditos: Esta parte de este laboratorio está tomado y basado en uno de los repositorios de Ben Trevett

Preparando la Data

Como la otra vez, volvemos a empezar importando las librerías necesarias. Así también seteamos la Seed para asegurar que las calificaciones sean consistentes.

Despues, al igual que en el lab anterior, haremos el tokenizador. Así mismo definimos mismo Field de la ultima vez con la diferencia menor que ahora estaremos pasando batches de datos, por ende usaremos el parámetro "batch_first=True"

Despues cargaremos el mismo dataset de la ultima vez "Multi30K" para construir nuestro vocabulario. Donde se cargan los sets de `train_data`, `valid_data` y `test_data`, hagan los cambios necesarios para cargar los datos como lo hicieron la última vez. **Siéntase libre de hacer copy-paste de lo que hicieron en el lab4.**

Finalmente, definiremos el `device` con el que estaremos trabajando. **Se recomienda usar CUDA.** Por otro lado, recuerden que tienen disponible el laboratorio del CIT-411 para que lo usen en el período de clase de los días lunes. En las máquinas de este laboratorio pueden usar CUDA y deberían ser más rápidas que los tiempos mostrados en este Notebook.

In [3]:

```
import torch
import torch.nn as nn
import torch.optim as optim

import torchtext
from torchtext.datasets import Multi30k
from torchtext.data import Field, BucketIterator

import matplotlib.pyplot as plt
import matplotlib.ticker as ticker

import spacy
import numpy as np

import random
import math
import time
```

In [6]:

```
random.seed(seed_)
np.random.seed(seed_)
torch.manual_seed(seed_)
torch.cuda.manual_seed(seed_)
torch.backends.cudnn.deterministic = True
```

In [7]:

```
spacy_de = spacy.load('de_core_news_sm')
spacy_en = spacy.load('en_core_web_sm')
```

In [8]:

```
def tokenize_de(text):
    return [tok.text for tok in spacy_de.tokenizer(text)]

def tokenize_en(text):
    return [tok.text for tok in spacy_en.tokenizer(text)]
```

In [9]:

```
# Noten el uso de batch_first
SRC = Field(tokenize = tokenize_de,
            init_token = '<sos>',
            eos_token = '<eos>',
            lower = True,
            batch_first = True)

TRG = Field(tokenize = tokenize_en,
            init_token = '<sos>',
            eos_token = '<eos>',
            lower = True,
            batch_first = True)
```

In [10]:

```
#train_data, valid_data, test_data = Multi30k.splits(exts = ('.de', '.en'),
#                                                    fields = (SRC, TRG))

# En esta sección hagan lo mismo que hicieron en el lab4 para cargar
# los datos necesarios por favor
train_data, valid_data, test_data = Multi30k.splits(exts = ('.de', '.en'),
                                                    fields = (SRC, TRG),
                                                    path = 'multi30k')
```

In [26]:

```
SRC.build_vocab(train_data, min_freq = 2)
TRG.build_vocab(train_data, min_freq = 2)
```

In [27]:

```
# Se recomienda el uso de CUDA
device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
print(device)
```

cpu

In [28]:

```
# Definimos el tamaño del batch y creamos iteradores
BATCH_SIZE = 128

train_iterator, valid_iterator, test_iterator = BucketIterator.splits(
    (train_data, valid_data, test_data),
    batch_size = BATCH_SIZE,
    device = device)
```

Construyendo el Modelo

A continuación, construiremos el modelo. Al igual que los notebook anteriores, se compone de un *encoder* y un *decoder*, con el encoder *codificando* la oración de entrada/fuente (en alemán) en *vector de contexto* y el decpder luego *decodificando* este vector de contexto para generar nuestra oración de salida/objetivo (en inglés)


Encoder

El codificador de Transformer no intenta comprimir la oración fuente completa, $X = (x_1, \dots, x_n)$, en un solo

vector de contexto, z . En su lugar, produce una secuencia de vectores de contexto, $Z = (z_1, \dots, z_n)$. Entonces, si

nuestra secuencia de entrada fuera de 5 tokens, tendríamos $Z = (z_1, z_2, z_3, z_4, z_5)$.

¿Por qué llamamos a esto una secuencia de vectores de contexto y no una secuencia de estados ocultos? Un estado oculto en el tiempo t en un RNN solo ha visto tokens x_t y todos los tokens anteriores. Sin embargo, cada vector de contexto aquí ha visto todos los tokens en todas las posiciones dentro de la secuencia de entrada.



Primero, los tokens se pasan a través de una capa de embedding estándar. Luego, como el modelo no tiene recurrencia, no tiene idea del orden de los tokens dentro de la secuencia. Resolvemos esto usando una segunda capa de embedding llamada *capa de positional embedding*. Esta es una capa de embedding estándar donde la

entrada no es el token en sí, sino la posición del token dentro de la secuencia, comenzando con el primer token, el token `<sos>` (inicio de secuencia), en la posición 0. La posición embbedida tiene un tamaño de "vocabulario" de 100, lo que significa que nuestro modelo puede aceptar oraciones de hasta 100 tokens de largo. Esto se puede aumentar si queremos manejar oraciones más largas.

La implementación original de Transformer del documento Attention is All You Need no aprende embedding posicionales. En su lugar, utiliza una incrustación estática fija. Las arquitecturas modernas de Transformer, como BERT, usan embedding posicionales en su lugar, por lo que lo haremos así en este laboratorio. Consulte [esta](#) sección para obtener más información sobre las positional embedding utilizadas en el modelo Transformer original.

A continuación, los embedding de tokens y posicionales se suman por elementos para obtener un vector que contiene información sobre el token y también su posición en la secuencia. Sin embargo, antes de que se sumen, las incrustaciones de tokens se multiplican por un factor de escala que es $\sqrt{d_{model}}$, donde d_{model} es el tamaño del hidden state, `hid_dim`. Esto supuestamente reduce la variación en las incorporaciones y el modelo es difícil de entrenar de manera confiable sin este factor de escala. A continuación, se aplica el dropout a las embeddings combinadas.

Las embedding combinadas luego se pasan a través de N capas de encoder para obtener Z , que luego se van de output y puede ser utilizado por el decoder.

La máscara fuente, `src_mask`, tiene simplemente la misma forma que la oración fuente pero tiene un valor de 1 cuando el token en la oración fuente no es un token `<pad>` y 0 cuando es un `<pad>` simbólico. Esto se usa en las capas del encoder para enmascarar los mecanismos de atención de múltiples cabezas, que se usan para calcular y aplicar atención sobre la oración fuente, por lo que el modelo no presta atención a los tokens `<pad>`, que no contienen información útil.

In [38]:

```
class Encoder(nn.Module):
    def __init__(self,
                  input_dim,
                  hid_dim,
                  n_layers,
                  n_heads,
                  pf_dim,
                  dropout,
                  device,
                  max_length = 100):
        super().__init__()

        self.device = device

        # Aprox 2 lineas para
        self.tok_embedding = nn.Embedding(input_dim, hid_dim)
        self.pos_embedding = nn.Embedding(max_length, hid_dim)

        self.layers = nn.ModuleList([EncoderLayer(hid_dim,
                                                    n_heads,
                                                    pf_dim,
                                                    dropout,
                                                    device)
                                      for _ in range(n_layers)])

        # Aprox 1 linea para
        self.dropout = nn.Dropout(dropout)

        self.scale = torch.sqrt(torch.FloatTensor([hid_dim])).to(device)

    def forward(self, src, src_mask):

        # Noten que el src y el src_mask son lista con informacion dentro de ellas
        #src = [batch size, src len]
        #src_mask = [batch size, 1, 1, src len]

        # Aprox 2 lineas para
        batch_size = src.shape[0]
```

```

src_len = src.shape[1]

pos = torch.arange(0, src_len).unsqueeze(0).repeat(batch_size, 1).to(self.device)

# Noten que pos tendrá información del batch y el tamaño del src
# pos = [batch size, src len]

src = self.dropout((self.tok_embedding(src) * self.scale) + self.pos_embedding(pos))

# src = [batch size, src len, hid dim]

for layer in self.layers:
    src = layer(src, src_mask)

# src = [batch size, src len, hid dim]

return src

```

Capa de Encoder

Las capas del encoder son donde está contenida toda la "carne" del codificador. Primero pasamos la oración fuente y su máscara a la *capa de atención de múltiples cabezas*, luego realizamos el dropout, aplicamos una conexión residual y la pasamos a través de una [Normalización de capa](#). Luego lo pasamos a través de una capa de *position-wise feedforward* y luego, nuevamente, aplicamos dropout, una conexión residual y luego la normalización de la capa para obtener la salida de esta capa que se alimenta a la siguiente capa. Los parámetros no se comparten entre capas.

La capa encoder utiliza la capa de atención de múltiples cabezas para prestar atención a la oración fuente, es decir, está calculando y aplicando atención sobre sí misma en lugar de sobre otra secuencia, por lo que la llamamos *autoatención*.

[Este](#) artículo entra en más detalles sobre la capa normalización, pero la esencia es que normaliza los valores de las features, es decir, a través de la hidden dimension, por lo que cada característica tiene una media de 0 y una desviación estándar de 1. Esto permite a las redes neuronales con una mayor cantidad de capas, como el Transformador, el poder entrenar más fácil.

In [39]:

```

class EncoderLayer(nn.Module):
    def __init__(self,
                 hid_dim,
                 n_heads,
                 pf_dim,
                 dropout,
                 device):
        super().__init__()

        # Definiendo los módulos de normalización de capa.
        self.self_attn_layer_norm = nn.LayerNorm(hid_dim)
        self.ff_layer_norm = nn.LayerNorm(hid_dim)

        self.self_attention = MultiHeadAttentionLayer(hid_dim, n_heads, dropout, device)
        self.positionwise_feedforward = PositionwiseFeedforwardLayer(hid_dim,
                                                                       pf_dim,
                                                                       dropout)

        self.dropout = nn.Dropout(dropout)

    def forward(self, src, src_mask):

        #src = [batch size, src len, hid dim]
        #src_mask = [batch size, 1, 1, src len]

        # Proceso de self attention.
        _src, _ = self.self_attention(src, src, src, src_mask)

        #dropout, residual connection y layer norm

```

```

src = self.self_attn_layer_norm(src + self.dropout(_src))

#src = [batch size, src len, hid dim]

#positionwise feedforward
_src = self.positionwise_feedforward(src)

#dropout, residual and layer norm
src = self.ff_layer_norm(src + self.dropout(_src))

#src = [batch size, src len, hid dim]


return src

```


Multi Head Attention Layer

Uno de los conceptos clave y novedosos introducidos por el artículo de Transformer es la *capa de atención de múltiples cabezas*.

Scaled Dot-Product Attention



Multi-Head Attention



La atención se puede considerar como *querys*, *keys* y *values*, donde la query se usa con la key para obtener un vector de atención (generalmente el resultado de una operación *softmax* y tiene todos los valores entre 0 y 1 que suma a 1) que luego se usa para obtener una suma ponderada de los values.

El transformador utiliza *atención de producto escalar "escalado"*, donde la query y la key se combinan tomando el producto escalar entre ellos, luego aplicando la operación *softmax* y escalando por d_k antes de finalmente multiplicar por el value. d_k que es la *dimensión de la cabeza*, `head_dim`, que explicaremos más adelante.

$$\begin{aligned}
 &\text{Atención}(Q, K, \\
 &\quad V) \\
 &= \text{Softmax} \\
 &\quad \left(\frac{QK^T}{\sqrt{d_k}} \right) V
 \end{aligned}$$

Esto es similar a la *atención estándar del producto escalar* pero se escala por d_k , que según el documento se usa para evitar que los resultados de los productos escalares crezcan demasiado, lo que hace que los gradientes se vuelvan demasiado pequeños.

Sin embargo, la atención del producto punto escalado no se aplica simplemente a las querys, keys y values. En lugar de hacer una sola aplicación de atención, las querys, las keys y los values tienen su `hid_dim` dividido en h *cabezas* y la atención del producto punto escalado se calcula sobre todas las cabezas en paralelo. Esto significa que en lugar de prestar atención a un concepto por aplicación de atención, prestamos atención a h .

Luego, volvemos a combinar las cabezas en su forma `hid_dim`, por lo que cada `hid_dim` esta potencialmente prestando atención a h conceptos diferentes.

$$\begin{aligned} & \text{MultiHead}(Q, K, \\ & \quad V) \\ &= \text{Concat}(\text{head}_1, \\ & \quad \dots, \text{head}_h) W^O \\ & \quad \text{cabeza}_i \\ &= \text{Atención} \\ & \quad (QW_i^Q, KW_i^K, \\ & \quad VW_i^V) \end{aligned}$$

W^O es la capa lineal aplicada al final de la capa de atención de múltiples cabezas, `fc`. W^Q, W^K, W^V son las capas lineales `fc_q`, `fc_k` y `fc_v`.

Recorriendo el módulo, primero calculamos QW^Q, KW^K y VW^V con las capas lineales, `fc_q`, `fc_k` y `fc_v`, para obtener `Q`, `K` y `V`. A continuación, dividimos `hid_dim` de la query, la key y el value en `n_heads` usando `.view` y los permutamos correctamente para que puedan multiplicarse entre sí. Luego calculamos la 'energía' (la atención no normalizada) multiplicando 'Q' y 'K' juntos y escalando por la raíz cuadrada de 'head_dim', que se calcula como 'hid_dim // n_heads'. Luego enmascaramos la energía para que no prestemos atención a ningún elemento de la secuencia que no deberíamos, luego aplicamos el softmax y el dropout. Luego aplicamos la atención a los valores caros, `V`, antes de combinar los `n_cabezas`. Finalmente, multiplicamos este W^O , representado por `fc_o`.

Note que en nuestra implementación, las longitudes de las keys y los values son siempre los mismos, por lo tanto, cuando la matriz multiplica la salida del softmax, `atención`, con `V`, siempre tendremos tamaños de dimensión válidos para la multiplicación de matrices. Esta multiplicación se lleva a cabo usando `torch.matmul` que, cuando ambos tensores son > bidimensionales, realiza una multiplicación matricial por batches sobre las dos últimas dimensiones de cada tensor. Esta será una [longitud de query, longitud de key] x [longitud de value, atenuación de cabezal] multiplicación de matriz por batches sobre el tamaño del batch y cada cabezal que proporciona el [tamaño de batch, n cabezales, longitud de query, atenuación de cabezal] resultado.

Una cosa que parece extraña al principio es que dropout se aplica directamente a la atención. Esto significa que nuestro vector de atención probablemente no sumará 1 y podemos prestar toda la atención a un token, pero la atención sobre ese token se establece en 0 por dropout. Esto nunca se explica, ni siquiera se menciona, en el documento; sin embargo, lo usa la [implementación oficial](https://github.com/google-research/bert/) y todas las implementaciones de Transformer desde [BERT] ([https:// github.com/google-research/bert/](https://github.com/google-research/bert/)).

In [40]:

```
class MultiHeadAttentionLayer(nn.Module):
    def __init__(self, hid_dim, n_heads, dropout, device):
        super().__init__()

        assert hid_dim % n_heads == 0

        self.hid_dim = hid_dim
        self.n_heads = n_heads
        self.head_dim = hid_dim // n_heads

        # Aprox 4 lineas para
        self.fc_q = nn.Linear(hid_dim, hid_dim)
        self.fc_k = nn.Linear(hid_dim, hid_dim)
        self.fc_v = nn.Linear(hid_dim, hid_dim)
        self.fc_o = nn.Linear(hid_dim, hid_dim)

        self.dropout = nn.Dropout(dropout)

        self.scale = torch.sqrt(torch.FloatTensor([self.head_dim])).to(device)

    def forward(self, query, key, value, mask = None):
```

```

batch_size = query.shape[0]

Q = self.fc_q(query)
K = self.fc_k(key)
V = self.fc_v(value)

Q = Q.view(batch_size, -1, self.n_heads, self.head_dim).permute(0, 2, 1, 3)

# Aproximadamente 2 líneas para
K = K.view(batch_size, -1, self.n_heads, self.head_dim).permute(0, 2, 1, 3)
V = V.view(batch_size, -1, self.n_heads, self.head_dim).permute(0, 2, 1, 3)

energy = torch.matmul(Q, K.permute(0, 1, 3, 2)) / self.scale

if mask is not None:
    energy = energy.masked_fill(mask == 0, -1e10)

attention = torch.softmax(energy, dim = -1)

x = torch.matmul(self.dropout(attention), V)

x = x.permute(0, 2, 1, 3).contiguous()

x = x.view(batch_size, -1, self.hid_dim)

x = self.fc_o(x)

return x, attention

```

Capa Position-wise Feedforward

El otro bloque principal dentro de la capa del encoder es la *capa de realimentación por posición* o *capa position-wise feedforward*. Es relativamente simple en comparación con la capa de atención multi-head. La entrada se transforma de `hid_dim` a `pf_dim`, donde `pf_dim` suele ser mucho más grande que `hid_dim`. El Transformer original usaba un `hid_dim` de 512 y un `pf_dim` de 2048. La función de activación y dropout de ReLU se aplica antes de que se transforme de nuevo en una representación `hid_dim`.

¿Por qué se usa esto? Desafortunadamente, nunca se explica en el documento.

BERT usa la función de activación [GELU](#), que se puede usar simplemente cambiando `torch.relu` por `F.gelu`. ¿Por qué usaron GELU? De nuevo, lastimosamente, no se explica.

In [41]:

```

class PositionwiseFeedforwardLayer(nn.Module):
    def __init__(self, hid_dim, pf_dim, dropout):
        super().__init__()

        # La primera capa lineal transforma desde hid_dim a pf_dim
        self.fc_1 = nn.Linear(hid_dim, pf_dim)
        # La segunda capa lineal transforma de vuelta desde pf_dim a hid_dim
        self.fc_2 = nn.Linear(pf_dim, hid_dim)

        self.dropout = nn.Dropout(dropout)

    def forward(self, x):
        #x = [batch size, seq len, hid dim]

        # Aplicamos la primera transformación lineal, luego ReLU, luego dropout
        x = self.dropout(torch.relu(self.fc_1(x)))

        #x = [batch size, seq len, pf dim]


        # Aplicamos la segunda transformación lineal
        x = self.fc_2(x)

        #x = [batch size, seq len, hid dim]

```

Decoder

El objetivo del decoder es tomar la representación codificada de la oración de origen, Z , y convertirla en tokens predichos en la oración de destino, \hat{Y} . Luego comparamos \hat{Y} con los tokens reales en la oración objetivo, Y , para calcular nuestra pérdida, que se usará para calcular los gradientes de nuestros parámetros y luego usamos nuestro optimizador para actualizar nuestros pesos en orden para mejorar nuestras predicciones.



El decoder es similar al encoder, sin embargo, ahora tiene dos capas de atención multi-head. Una *capa de atención multi-head enmascarada* sobre la secuencia de destino y una capa de atención multi-head que utiliza la representación del decoder como consulta y la representación del encoder como clave y valor.

El decoder utiliza positional embeddings y las combina, a través de una suma de elementos, con los tokens de destino embebidos escalados, seguidos de dropout. Nuevamente, nuestras codificaciones posicionales tienen un "vocabulario" de 100, lo que significa que pueden aceptar secuencias de hasta 100 tokens de largo. Esto se puede aumentar si se desea.

Las embeddings combinadas luego se pasan a través de las capas del decodificador N , junto con la fuente codificada, `enc_src`, y las máscaras de origen y destino. Considere que la cantidad de capas en el encoder no tiene que ser igual a la cantidad de capas en el decoder, aunque ambas se indican con N .

La representación del decoder después de la capa N^{th} se pasa a través de una capa lineal, `fc_out`. En PyTorch, la operación softmax está contenida dentro de nuestra función de pérdida, por lo que no necesitamos usar explícitamente una capa softmax aquí.

Además de usar la máscara de origen, como hicimos en el encoder para evitar que nuestro modelo preste atención a los tokens `<pad>`, también usamos una máscara de destino. Esto se explicará con más detalle en el modelo `Seq2Seq` que encapsula tanto el encoder como el decoder. Como estamos procesando todos los tokens de destino a la vez en paralelo, necesitamos un método para evitar que el decoder "haga trampa"

simplemente "mirando" cual es el siguiente token en la secuencia de destino y emitiendolo.

Nuestra capa de decoder también genera los valores de atención normalizados para que luego podamos trazarlos y ver a qué está prestando atención nuestro modelo.

In [42]:

```
class Decoder(nn.Module):
    def __init__(self,
                  output_dim,
                  hid_dim,
                  n_layers,
                  n_heads,
                  pf_dim,
                  dropout,
                  device,
                  max_length = 100):
        super().__init__()

        self.device = device

        # El tok_embedding convierte los tokens de salida en vectores
        self.tok_embedding = nn.Embedding(output_dim, hid_dim)
        # El pos_embedding añade información posicional a estos vectores
        self.pos_embedding = nn.Embedding(max_length, hid_dim)

        self.layers = nn.ModuleList()
        for _ in range(n_layers):
            # Añadir una nueva capa de decodificador a la lista de capas
            layer = DecoderLayer(hid_dim, n_heads, pf_dim, dropout, device)
            self.layers.append(layer)

        self.fc_out = nn.Linear(hid_dim, output_dim)
        self.dropout = nn.Dropout(dropout)
        self.scale = torch.sqrt(torch.FloatTensor([hid_dim])).to(device)

    def forward(self, trg, enc_src, trg_mask, src_mask):

        #trg = [batch size, trg len]
        #enc_src = [batch size, src len, hid dim]
        #trg_mask = [batch size, 1, trg len, trg len]
        #src_mask = [batch size, 1, 1, src len]

        batch_size = trg.shape[0]
        trg_len = trg.shape[1]

        pos = torch.arange(0, trg_len).unsqueeze(0).repeat(batch_size, 1).to(self.device)

        #pos = [batch size, trg len]

        trg = self.dropout((self.tok_embedding(trg) * self.scale) + self.pos_embedding(pos))

        #trg = [batch size, trg len, hid dim]

        for layer in self.layers:
            trg, attention = layer(trg, enc_src, trg_mask, src_mask)

        #trg = [batch size, trg len, hid dim]
        #attention = [batch size, n heads, trg len, src len]

        output = self.fc_out(trg)

        #output = [batch size, trg len, output dim]

        return output, attention
```

Decoder Layer

Como se mencionó antes, la capa del decoder es similar a la capa del encoder, excepto que ahora tiene dos

Como se mencionó antes, la capa del decoder es similar a la capa del encoder, excepto que ahora tiene dos capas de atención multi-head, `self_attention` y `encoder_attention`.

El primero realiza la autoatención, como en el encoder, utilizando la representación del decoder en cuanto a query, key y value. A esto le sigue el dropout, la conexión residual y la normalización de capas. Esta capa `self_attention` utiliza la máscara de secuencia de destino, `trg_mask`, para evitar que el decoder "haga trampa" al prestar atención a los tokens que están "por delante" del que está procesando actualmente, ya que procesa todos los tokens en el objetivo. oración en paralelo.

El segundo es cómo alimentamos la oración fuente codificada, `enc_src`, en nuestro decoder. En esta capa de atención de multi-head, las queries son las representaciones del decoder y las keys y los values son las representaciones del encoder. Aquí, la máscara de origen, `src_mask` se usa para evitar que la capa de atención multi-head preste atención a los tokens `<pad>` dentro de la oración de origen. A esto le siguen las capas de dropout, conexión residual y normalización de capas.

Finalmente, pasamos esto a través de la capa de position-wise feedforward y otra secuencia más de dropout, conexión residual y normalización de capa.

La capa del decoder no presenta ningún concepto nuevo, solo usa el mismo conjunto de capas que el encoder de una manera ligeramente diferente.

In [43]:

```
class DecoderLayer(nn.Module):
    def __init__(self,
                 hid_dim,
                 n_heads,
                 pf_dim,
                 dropout,
                 device):
        super().__init__()

        # La normalización de capas es utilizada antes de cada sub-capa en el transformad
or.

        self.self_attn_layer_norm = nn.LayerNorm(hid_dim)
        self.enc_attn_layer_norm = nn.LayerNorm(hid_dim)
        self.ff_layer_norm = nn.LayerNorm(hid_dim)

        self.self_attention = MultiHeadAttentionLayer(hid_dim, n_heads, dropout, device)
        self.encoder_attention = MultiHeadAttentionLayer(hid_dim, n_heads, dropout, devi
ce)

        self.positionwise_feedforward = PositionwiseFeedforwardLayer(hid_dim,
                                                                    pf_dim,
                                                                    dropout)

        self.dropout = nn.Dropout(dropout)

    def forward(self, trg, enc_src, trg_mask, src_mask):

        #trg = [batch size, trg len, hid dim]
        #enc_src = [batch size, src len, hid dim]
        #trg_mask = [batch size, 1, trg len, trg len]
        #src_mask = [batch size, 1, 1, src len]

        #self attention
        _trg, _ = self.self_attention(trg, trg, trg, trg_mask)

        #dropout, residual connection and layer norm
        trg = self.self_attn_layer_norm(trg + self.dropout(_trg))

        #trg = [batch size, trg len, hid dim]

        #encoder attention
        _trg, attention = self.encoder_attention(trg, enc_src, enc_src, src_mask)

        #dropout, residual connection and layer norm
        trg = self.enc_attn_layer_norm(trg + self.dropout(_trg))

        #trg = [batch size, trg len, hid dim]
```

Modelo Seq2Seq

La máscara de origen se crea comprobando dónde la secuencia de origen no es igual a un token `<pad>` . Es 1 cuando el token no es un token `<pad>` y 0 cuando lo es. Luego se descomprime para que pueda transmitirse correctamente al aplicar la máscara a la `energía` , que tiene la forma *[tamaño del batch, n cabezas, seq len, seq len]*.

10000
11000
11100
11110
11111

10000
11000
11100
11100
11100

```
class Seq2Seq(nn.Module):
    def __init__(self,
                  encoder,
                  decoder,
                  src_pad_idx,
                  trg_pad_idx,
                  device):
        super().init_()
```

```

self.encoder = encoder
self.decoder = decoder
self.src_pad_idx = src_pad_idx
self.trg_pad_idx = trg_pad_idx
self.device = device

def make_src_mask(self, src):

    #src = [batch size, src len]

    src_mask = (src != self.src_pad_idx).unsqueeze(1).unsqueeze(2)

    #src_mask = [batch size, 1, 1, src len]

    return src_mask

def make_trg_mask(self, trg):

    #trg = [batch size, trg len]

    trg_pad_mask = (trg != self.trg_pad_idx).unsqueeze(1).unsqueeze(2)

    #trg_pad_mask = [batch size, 1, 1, trg len]

    trg_len = trg.shape[1]

    trg_sub_mask = torch.tril(torch.ones((trg_len, trg_len), device = self.device)).
bool()

    #trg_sub_mask = [trg len, trg len]

    trg_mask = trg_pad_mask & trg_sub_mask

    #trg_mask = [batch size, 1, trg len, trg len]

    return trg_mask

def forward(self, src, trg):

    #src = [batch size, src len]
    #trg = [batch size, trg len]

    src_mask = self.make_src_mask(src)
    trg_mask = self.make_trg_mask(trg)

    #src_mask = [batch size, 1, 1, src len]
    #trg_mask = [batch size, 1, trg len, trg len]

    enc_src = self.encoder(src, src_mask)

    #enc_src = [batch size, src len, hid dim]

    output, attention = self.decoder(trg, enc_src, trg_mask, src_mask)

    #output = [batch size, trg len, output dim]
    #attention = [batch size, n heads, trg len, src len]

    return output, attention

```

Entrenamiento

Ahora ya podemos entrenar nuestro modelo, el cual es más pequeño que el modelo usado en el paper original, pero es lo suficientemente robusto.

Luego, vamos a definir nuestro modelo completo sequence-to-sequence.

Después, creamos una función para contar el número de parámetros, notando que esta vez ya estamos hablando de millones de parametros dentro de un modelo.

Más tarde, definimos la forma de iniciar los pesos, usando una técnica conocida como Xavier uniform.

Luego, el optimizador utilizado con un learning rate fijo es declarado. Consideren que el learning rate debe ser inferior a la predeterminada utilizada por Adam o, de lo contrario, el aprendizaje es inestable.

In [46]:

```
INPUT_DIM = len(SRC.vocab)
OUTPUT_DIM = len(TRG.vocab)
HID_DIM = 256
ENC_LAYERS = 3
DEC_LAYERS = 3
ENC_HEADS = 8
DEC_HEADS = 8
ENC_PF_DIM = 512
DEC_PF_DIM = 512
ENC_DROPOUT = 0.1
DEC_DROPOUT = 0.1

enc = Encoder(INPUT_DIM,
               HID_DIM,
               ENC_LAYERS,
               ENC_HEADS,
               ENC_PF_DIM,
               ENC_DROPOUT,
               device)

dec = Decoder(OUTPUT_DIM,
               HID_DIM,
               DEC_LAYERS,
               DEC_HEADS,
               DEC_PF_DIM,
               DEC_DROPOUT,
               device,
               max_length=100)  # Puedes cambiar este valor según tus necesidades.
```

In [47]:

```
SRC_PAD_IDX = SRC.vocab.stoi[SRC.pad_token]
TRG_PAD_IDX = TRG.vocab.stoi[TRG.pad_token]

model = Seq2Seq(enc, dec, SRC_PAD_IDX, TRG_PAD_IDX, device).to(device)
```

In [48]:

```
def count_parameters(model):
    return sum(p.numel() for p in model.parameters() if p.requires_grad)

print(f'The model has {count_parameters(model):,} trainable parameters')
```

The model has 9,038,341 trainable parameters

In [49]:

```
def initialize_weights(m):
    if hasattr(m, 'weight') and m.weight.dim() > 1:
        nn.init.xavier_uniform_(m.weight.data)
```

In [50]:

```
model.apply(initialize_weights);
```

In [51]:

```
LEARNING_RATE = 0.0005

optimizer = torch.optim.Adam(model.parameters(), lr = LEARNING_RATE)
```

In [52]:

```
criterion = nn.CrossEntropyLoss(ignore_index = TRG_PAD_IDX)
```


Como queremos que nuestro modelo prediga el token `<eos>` pero no que sea una entrada en nuestro modelo, simplemente cortamos el token `<eos>` del final de la secuencia. De este modo:

$$\begin{aligned} & \text{Atención} \\ & (Q, K, V) \\ & = \text{Softmax} \\ & \left(\frac{QK^T}{\sqrt{d_k}} \right) V \\ & \text{trg} = [\text{sos}, \\ & \quad x_1, x_2, x_3, \\ & \quad \text{eos}] \\ & \text{trg}[:-1] \\ & = [\text{sos}, x_1, \\ & \quad x_2, x_3] \end{aligned}$$

x_i denota el elemento de secuencia de destino real. Luego ingresamos esto en el modelo para obtener una secuencia predicha que debería predecir el token `<eos>`:

$$\begin{aligned} & \text{salida} \\ & = [y_1, y_2, \\ & \quad y_3, \text{eos}] \end{aligned}$$

y_i denota el elemento de secuencia de destino predicho. Luego calculamos nuestra pérdida usando el tensor `trg` original con el token `<sos>` cortado del frente, dejando el token `<eos>`:

$$\begin{aligned} & \text{salida} \\ & = [y_1, y_2, \\ & \quad y_3, \text{eos}] \\ & \text{trg}[1:] \\ & = [x_1, x_2, \\ & \quad x_3, \text{eos}] \end{aligned}$$

Luego calculamos nuestras losses y actualizamos nuestros parámetros como es estándar.

In [59]:

```
def train(model, iterator, optimizer, criterion, clip):

    model.train()

    epoch_loss = 0

    for i, batch in enumerate(iterator):

        src = batch.src
        trg = batch.trg

        optimizer.zero_grad()

        output, _ = model(src, trg[:, :-1])

        #output = [batch size, trg len - 1, output dim]
        #trg = [batch size, trg len]

        output_dim = output.shape[-1]

        # Cambiando las dimensiones de 'output' para que coincidan con las de 'trg'
        output = output.contiguous().view(-1, output_dim)
        trg = trg[:, 1:].contiguous().view(-1)

        #output = [batch size * trg len - 1, output dim]
        #trg = [batch size * trg len - 1]
```

```

    loss = criterion(output, trg)

    loss.backward()

    torch.nn.utils.clip_grad_norm_(model.parameters(), clip)

    optimizer.step()

    epoch_loss += loss.item()

    return epoch_loss / len(iterator)

```

El ciclo de evaluación es el mismo que el del entrenamiento pero sin la parte de la graiente y la actualizacion de los parametros

In [60]:

```

def evaluate(model, iterator, criterion):

    model.eval()

    epoch_loss = 0

    with torch.no_grad():

        for i, batch in enumerate(iterator):

            src = batch.src
            trg = batch.trg

            output, _ = model(src, trg[:, :-1])

            #output = [batch size, trg len - 1, output dim]
            #trg = [batch size, trg len]

            output_dim = output.shape[-1]

            output = output.contiguous().view(-1, output_dim)
            trg = trg[:, 1:].contiguous().view(-1)

            #output = [batch size * trg len - 1, output dim]
            #trg = [batch size * trg len - 1]

            loss = criterion(output, trg)

            epoch_loss += loss.item()

    return epoch_loss / len(iterator)

```

In [61]:

```

def epoch_time(start_time, end_time):
    elapsed_time = end_time - start_time
    elapsed_mins = int(elapsed_time / 60)
    elapsed_secs = int(elapsed_time - (elapsed_mins * 60))
    return elapsed_mins, elapsed_secs

```

In [63]:

```

# Una linea para definir el numero de epocas
N_EPOCHS = 10
# YOUR CODE HERE
CLIP = 1

best_valid_loss = float('inf')

for epoch in range(N_EPOCHS):

    start_time = time.time()

```

```

train_loss = train(model, train_iterator, optimizer, criterion, CLIP)
valid_loss = evaluate(model, valid_iterator, criterion)

end_time = time.time()

epoch_mins, epoch_secs = epoch_time(start_time, end_time)

if valid_loss < best_valid_loss:
    best_valid_loss = valid_loss
    torch.save(model.state_dict(), 'tut6-model.pt')

print(f'Epoch: {epoch+1:02} | Time: {epoch_mins}m {epoch_secs}s')
print(f'\tTrain Loss: {train_loss:.3f} | Train PPL: {math.exp(train_loss):7.3f}')
print(f'\tVal. Loss: {valid_loss:.3f} | Val. PPL: {math.exp(valid_loss):7.3f}')

```

```

Epoch: 01 | Time: 2m 29s
  Train Loss: 4.229 | Train PPL: 68.659
  Val. Loss: 3.061 | Val. PPL: 21.350
Epoch: 02 | Time: 2m 25s
  Train Loss: 2.852 | Train PPL: 17.315
  Val. Loss: 2.336 | Val. PPL: 10.342
Epoch: 03 | Time: 2m 36s
  Train Loss: 2.256 | Train PPL: 9.542
  Val. Loss: 1.997 | Val. PPL: 7.367
Epoch: 04 | Time: 2m 25s
  Train Loss: 1.896 | Train PPL: 6.659
  Val. Loss: 1.830 | Val. PPL: 6.232
Epoch: 05 | Time: 2m 25s
  Train Loss: 1.644 | Train PPL: 5.177
  Val. Loss: 1.705 | Val. PPL: 5.503
Epoch: 06 | Time: 2m 26s
  Train Loss: 1.456 | Train PPL: 4.287
  Val. Loss: 1.656 | Val. PPL: 5.238
Epoch: 07 | Time: 2m 22s
  Train Loss: 1.298 | Train PPL: 3.664
  Val. Loss: 1.634 | Val. PPL: 5.122
Epoch: 08 | Time: 2m 21s
  Train Loss: 1.173 | Train PPL: 3.232
  Val. Loss: 1.614 | Val. PPL: 5.021
Epoch: 09 | Time: 2m 22s
  Train Loss: 1.063 | Train PPL: 2.896
  Val. Loss: 1.625 | Val. PPL: 5.079
Epoch: 10 | Time: 2m 24s
  Train Loss: 0.968 | Train PPL: 2.633
  Val. Loss: 1.628 | Val. PPL: 5.092

```

In [64]:

```

model.load_state_dict(torch.load('tut6-model.pt'))

test_loss = evaluate(model, test_iterator, criterion)

print(f'| Test Loss: {test_loss:.3f} | Test PPL: {math.exp(test_loss):7.3f} |')

| Test Loss: 1.669 | Test PPL: 5.305 |

```

NB: La **perplejidad (PPL)** es una medida utilizada para evaluar la efectividad de un modelo de lenguaje al predecir una secuencia de palabras. Cuantifica qué tan bien el modelo predice la siguiente palabra en una secuencia basada en las palabras anteriores. Una perplejidad más baja indica que el modelo tiene más certeza y precisión en sus predicciones, lo que refleja una mejor comprensión del lenguaje. Por otro lado, una perplejidad más alta sugiere que el modelo tiene menos certeza y le cuesta predecir la siguiente palabra con precisión. La perplejidad se utiliza comúnmente en el procesamiento del lenguaje natural para evaluar la calidad de los modelos de lenguaje, especialmente en tareas como la traducción automática y la generación de texto.

In [67]:

```

with tick.marks(25):
    assert compare_numbers(new_representation(test_loss), "3c3d", '0x1.ae147ae147ae1p+0'
    )

```

```
with tick.marks(25):
    assert compare_numbers(new_representation(math.exp(test_loss)), "3c3d", '0x1.570a3d70a3d71p+2')
```

✓ [25 marks]

✓ [25 marks]

Inferencia

Ahora traduciremos desde nuestro modelo con la funcion dada abajo.

Los pasos tomados son:

- Tokenizar la oración fuente si no ha sido tokenizada (es una cadena)
- Agregar los tokens `<sos>` y `<eos>`
- Numerizar la oración fuente
- Convertirlo en un tensor y agregue una dimensión de lote
- Crear la máscara de oración fuente
- Introduce la oración fuente y la máscara en el codificador
- Cree una lista para contener la oración de salida, inicializada con un token `<sos>`
- Si bien no hemos alcanzado una longitud máxima
 - Convertir la predicción de la oración de salida actual en un tensor con una dimensión por lotes
 - Crear una máscara de oración objetivo
 - Coloque la salida actual, la salida del codificador y ambas máscaras en el decodificador
 - Obtenga la próxima predicción del token de salida del decodificador junto con la atención
 - Agregue predicción a la predicción de oración de salida actual
 - Interrumpir si la predicción fue un token `<eos>`
- Convertir la oración de salida de índices a tokens
- Devolver la oración de salida (con el token `<sos>` eliminado) y la atención de la última capa

In [68]:

```
def translate_sentence(sentence, src_field, trg_field, model, device, max_len = 50):

    model.eval()

    if isinstance(sentence, str):
        nlp = spacy.load('de_core_news_sm')
        tokens = [token.text.lower() for token in nlp(sentence)]
    else:
        tokens = [token.lower() for token in sentence]

    tokens = [src_field.init_token] + tokens + [src_field.eos_token]
    src_indexes = [src_field.vocab.stoi[token] for token in tokens]
    src_tensor = torch.LongTensor(src_indexes).unsqueeze(0).to(device)
    src_mask = model.make_src_mask(src_tensor)

    with torch.no_grad():
        enc_src = model.encoder(src_tensor, src_mask)

    trg_indexes = [trg_field.vocab.stoi[trg_field.init_token]]

    for i in range(max_len):

        trg_tensor = torch.LongTensor(trg_indexes).unsqueeze(0).to(device)
        trg_mask = model.make_trg_mask(trg_tensor)

        with torch.no_grad():
            output, attention = model.decoder(trg_tensor, enc_src, trg_mask, src_mask)
```

```

pred_token = output.argmax(2)[:, -1].item()
trg_indexes.append(pred_token)

if pred_token == trg_field.vocab.stoi[trg_field.eos_token]:
    break

trg_tokens = [trg_field.vocab.itos[i] for i in trg_indexes]

return trg_tokens[1:], attention

```

Ahora definiremos una función que muestra la atención sobre la oración fuente para cada paso de la decodificación. Como este modelo tiene 8 cabezas, nuestro modelo puede ver la atención de cada una de las cabezas.

In [69]:

```

def display_attention(sentence, translation, attention, n_heads = 8, n_rows = 4, n_cols = 2):

    assert n_rows * n_cols == n_heads

    fig = plt.figure(figsize=(15,25))

    for i in range(n_heads):

        ax = fig.add_subplot(n_rows, n_cols, i+1)

        _attention = attention.squeeze(0)[i].cpu().detach().numpy()

        cax = ax.matshow(_attention, cmap='bone')

        ax.tick_params(labelsize=12)
        ax.set_xticklabels([''] + ['<sos>'] + [t.lower() for t in sentence] + ['<eos>'],
                           rotation=45)
        ax.set_yticklabels([''] + translation)

        ax.xaxis.set_major_locator(ticker.MultipleLocator(1))
        ax.yaxis.set_major_locator(ticker.MultipleLocator(1))

    plt.show()
    plt.close()

```

Ahora es momento de probar nuestro modelo! 😊

In [70]:

```

example_idx = 8

src = vars(train_data.examples[example_idx])['src']
trg = vars(train_data.examples[example_idx])['trg']

print(f'src = {src}')
print(f'trg = {trg}')

```

```

src = ['eine', 'frau', 'mit', 'einer', 'großen', 'geldbörse', 'geht', 'an', 'einem', 'tor',
      'vorbei', '.']
trg = ['a', 'woman', 'with', 'a', 'large', 'purse', 'is', 'walking', 'by', 'a', 'gate', '.']

```

In [71]:

```

translation, attention = translate_sentence(src, SRC, TRG, model, device)

print(f'predicted trg = {translation}')

```

```

predicted_trg = ['a', 'woman', 'with', 'a', 'large', 'purse', 'walks', 'past', 'a', 'gate',
                 ' ', ' ', ' ', '<eos>']

```

In [72]:

```
with tick.marks(50):
    assert compare_lists_by_percentage(trg, translation, 50)
```





✓ [50 marks]



Podemos ver la atención de cada cabeza a continuación. Cada uno es ciertamente diferente, pero es difícil (quizás imposible) razonar sobre a qué ha aprendido realmente la cabeza a prestar atención. Algunas cabezas prestan toda su atención a "eine" cuando traducen "a", otras no lo hacen en absoluto y otras un poco. Todos parecen seguir el patrón similar de "escalera descendente" y la atención al emitir los dos últimos tokens se distribuye por igual entre los dos últimos tokens en la oración de entrada.

In [73]:

```
display_attention(src, translation, attention)
```

```
/var/folders/h4/rlgjjv6s50z2sflx2_9bt49h0000gn/T/ipykernel_6248/3470126203.py:16: UserWarning: FixedFormatter should only be used together with FixedLocator
ax.set_xticklabels(['']+['<sos>']+ [t.lower() for t in sentence]+['<eos>'],
/var/folders/h4/rlgjjv6s50z2sflx2_9bt49h0000gn/T/ipykernel_6248/3470126203.py:18: UserWarning: FixedFormatter should only be used together with FixedLocator
ax.set_yticklabels(['']+translation)
```





In [74]:

```
example_idx = 7
```

```
src = vars(valid_data.examples[example_idx])['src']
trg = vars(valid_data.examples[example_idx])['trg']
```

```
print(f'src = {src}')
print(f'trg = {trg}')
```

```
src = ['ein', 'kleiner', 'junge', 'mit', 'einem', 'giants-trikot', 'schwingt', 'einen', 'baseballschläger', 'in', 'richtung', 'eines', 'ankommenden', 'balls', '.']
trg = ['a', 'young', 'boy', 'wearing', 'a', 'giants', 'jersey', 'swings', 'a', 'baseball', 'bat', 'at', 'an', 'incoming', 'pitch', '.']
```

In [75]:

```
translation, attention = translate_sentence(src, SRC, TRG, model, device)
```

```
print(f'predicted trg = {translation}')
```

```
predicted_trg = ['a', 'little', 'boy', 'wearing', 'a', 'baseball', 'cap', 'swings', 'a', 'baseball', 'bat', 'at', 'an', 'alley', '.', '<eos>']
```

In [76]:

```
with tick.marks(50):
    assert compare_lists_by_percentage(trg, translation, 30)
```

✓ [50 marks]


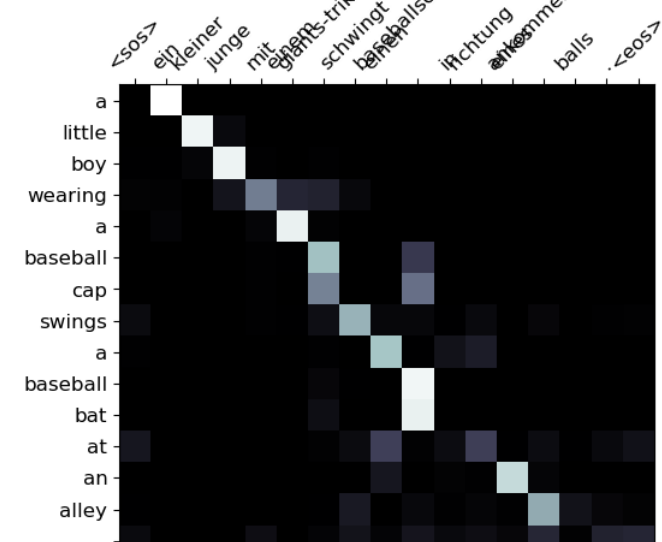




Una vez más, algunas cabezas prestan toda su atención a "ein", mientras que otras no le prestan atención. Una vez más, la mayoría de los heads parecen extender su atención sobre los tokens de punto y en la oración de origen cuando emiten el punto y la oración en la oración de destino predicha, aunque algunos parecen prestar


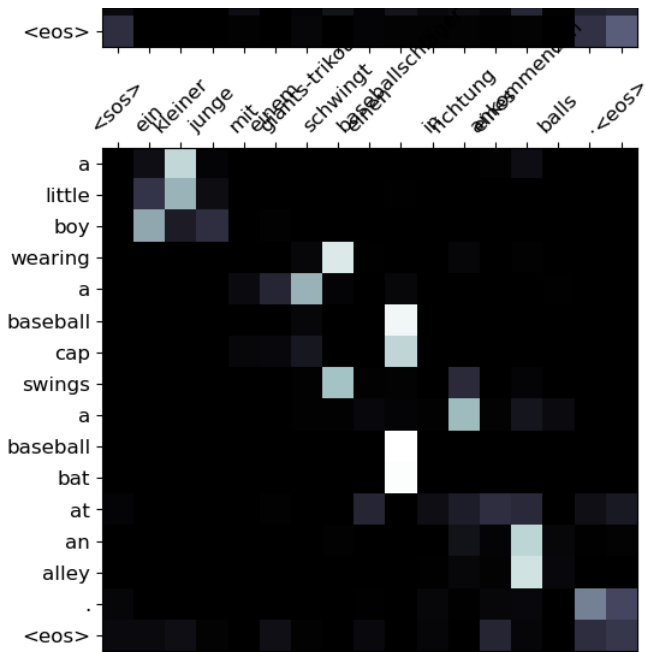
atencion a los tokens cerca del comienzo de la oracion.

In [77]:

```
display_attention(src, translation, attention)
```

```
/var/folders/h4/rlgjjv6s50z2sflx2_9bt49h0000gn/T/ipykernel_6248/3470126203.py:16: UserWarning: FixedFormatter should only be used together with FixedLocator
  ax.set_xticklabels(['']+['<sos>']+ [t.lower() for t in sentence]+['<eos>'],
/var/folders/h4/rlgjjv6s50z2sflx2_9bt49h0000gn/T/ipykernel_6248/3470126203.py:18: UserWarning: FixedFormatter should only be used together with FixedLocator
  ax.set_yticklabels(['']+translation)
```





In [78]:

```
example_idx = 10

src = vars(test_data.examples[example_idx])['src']
trg = vars(test_data.examples[example_idx])['trg']

print(f'src = {src}')
print(f'trg = {trg}')
```

```
src = ['eine', 'mutter', 'und', 'ihr', 'kleiner', 'sohn', 'genießen', 'einen', 'schönen',
'tag', 'im', 'freien', '.']
trg = ['a', 'mother', 'and', 'her', 'young', 'song', 'enjoying', 'a', 'beautiful', 'day',
'outside', '.']
```

In [79]:

```
translation, attention = translate_sentence(src, SRC, TRG, model, device)
print(f'predicted trg = {translation}')
```

```
predicted trg = ['a', 'mother', 'and', 'her', 'son', 'enjoy', 'a', 'beautiful', 'day', '.',
',', '<eos>']
```

In [80]:

```
with tick.marks(50):
    assert compare_lists_by_percentage(trg, translation, 33.2)
```

```
/Users/fredyvelasquez/anaconda3/lib/python3.10/site-packages/lautils/gradeutils.py:38: UserWarning: List are of different size.
warnings.warn("List are of different size.", UserWarning)
```









✓ [50 marks]

In [81]:

```
display_attention(src, translation, attention)
```

```
/var/folders/h4/rlgjjv6s50z2sflx2_9bt49h0000gn/T/ipykernel_6248/3470126203.py:16: UserWarning: FixedFormatter should only be used together with FixedLocator
ax.set_xticklabels(['']+['<sos>']+['<eos>'],
/var/folders/h4/rlgjjv6s50z2sflx2_9bt49h0000gn/T/ipykernel_6248/3470126203.py:18: UserWarning: FixedFormatter should only be used together with FixedLocator
ax.set_yticklabels(['']+translation)
```

<sos> eitter d . iner hn nießen en können . ien <sos> <sos> eitter d . iner hn nießen en können . ien <sos>



Calculamos el score BLEU

NB: El score BLEU (Bilingual Evaluation Understudy) es una métrica para evaluar la calidad de las traducciones generadas por máquinas en comparación con referencias humanas. Mide la superposición de secuencias de n-gramas entre la traducción generada por la máquina y las traducciones de referencia. BLEU calcula la precisión contando los n-gramas coincidentes y también aplica una penalización por brevedad para fomentar traducciones más largas. Produce un puntaje entre 0 y 1, siendo puntajes más altos indicativos de una mejor calidad de traducción, aunque no captura todas las sutilezas de la calidad de la traducción.

In [82]:

```
from torchtext.data.metrics import bleu_score

def calculate_bleu(data, src_field, trg_field, model, device, max_len = 50):

    trgs = []
    pred_trgs = []

    for datum in data:

        src = vars(datum)['src']
        trg = vars(datum)['trg']

        pred_trg, _ = translate_sentence(src, src_field, trg_field, model, device, max_l
en)

        #cut off <eos> token
        pred_trg = pred_trg[:-1]

        pred_trgs.append(pred_trg)
        trgs.append([trg])

    return bleu_score(pred_trgs, trgs)
```

In [83]:

```
bleu_score_ = calculate_bleu(test_data, SRC, TRG, model, device)

print(f'BLEU score = {bleu_score_*100:.2f}')
```

BLEU score = 34.77

In [84]:

```
with tick.marks(50):
    assert compare_numbers(new_representation(bleu_score_), "3e3d", '0x1.5c28f5c28f5c3p-
2')
```

✓ [50 marks]

PREGUNTAS: Responda las siguientes preguntas en este espacio (10% de la nota)

- ¿Cómo afecta la cantidad de parámetros del modelo? ¿Qué nos dicen eso 9M de parametros del modelo que hemos creado?
1. **Capacidad del Modelo:** Un modelo con más parámetros tiene, en teoría, una mayor capacidad para aprender de los datos, ya que puede ajustar más "interruptores" para representar relaciones complejas en los datos. Sin embargo, esto no garantiza automáticamente un mejor rendimiento. Aunque un modelo pueda representar una amplia variedad de funciones, necesita datos adecuados y suficientes para aprender las relaciones correctas.
 2. **Riesgo de Sobreajuste:** Mientras más parámetros tenga un modelo, mayor es el riesgo de que el modelo se sobreajuste (overfit) a los datos de entrenamiento. Sobreajuste ocurre cuando el modelo se desempeña excepcionalmente bien en los datos de entrenamiento pero mal en datos no vistos (datos de validación o prueba). Es esencial tener un conjunto de datos grande y diverso para entrenar modelos con una gran cantidad de parámetros.

- cantidad de parámetros.
3. **Tiempo y Recursos de Entrenamiento:** Modelos con más parámetros generalmente requieren más tiempo y recursos computacionales (como memoria y capacidad de procesamiento) para entrenarse. Esto se debe a que hay más cálculos que realizar y más valores que ajustar durante el proceso de optimización.
 4. **Interpretabilidad:** Modelos con menos parámetros suelen ser más fáciles de interpretar que aquellos con muchos parámetros. Sin embargo, modelos como las redes neuronales, en particular modelos profundos como los Transformers que estamos considerando, ya son inherentemente difíciles de interpretar incluso antes de considerar su tamaño.

En relación a los 9M La cantidad de parámetros de un modelo tiene varias implicaciones:

- Indica que es un modelo moderadamente grande. En el contexto de los modelos Transformer, 9M de parámetros es una cantidad significativa, pero todavía está en el extremo más pequeño en comparación con algunos de los modelos de lenguaje más grandes, como GPT-3 de OpenAI, que tiene 175 mil millones de parámetros.
- La cantidad específica de parámetros se determina por la arquitectura y las dimensiones que has elegido (como `HID_DIM`, `ENC_LAYERS`, `DEC_LAYERS`, etc.). Estos números determinan el tamaño y la profundidad de las redes en el encoder y el decoder.
- Si bien 9M de parámetros le da al modelo una buena capacidad para aprender relaciones en los datos, también significa que hay que ser cautelosos con el sobreajuste, especialmente si el conjunto de datos es relativamente pequeño. Es esencial utilizar técnicas como la regularización, el dropout y tener un conjunto de validación para monitorear el rendimiento del modelo en datos no vistos.
- ¿Qué hace el algoritmo de inicialización de Xavier Uniform?

Es una técnica específica para inicializar los pesos de las redes neuronales. Es especialmente útil para mejorar la convergencia en redes neuronales profundas. La idea detrás de esta inicialización es mantener la varianza de las activaciones y los gradientes aproximadamente igual en todas las capas.

Si las varianzas de las activaciones o gradientes son demasiado grandes o demasiado pequeñas mientras se avanza a través de las capas, esto puede llevar a problemas de desvanecimiento o explosión del gradiente, respectivamente. Estos problemas pueden hacer que el entrenamiento de la red neural sea lento o incluso inviable.

- ¿Qué hace el comando `torch.no_grad()`?

Desactiva la creación y el seguimiento del gráfico de cómputo, lo que significa que las operaciones realizadas dentro de este contexto no rastrearán las operaciones para calcular gradientes.

- Interprete el valor obtenido para el BLEU score ¿es nuestro modelo un buen modelo?

El BLEU (Bilingual Evaluation Understudy) score es una métrica para evaluar la calidad de textos traducidos por máquinas. El valor de BLEU puede variar entre 0 y 100, donde un valor más alto indica una mejor correspondencia entre las traducciones del modelo y las traducciones de referencia (humanas).

El valor fue de 34.77 y es considerado relativamente bueno dadas las circunstancias pero aún se puede encontrar mucho margen de mejora, y, tomando en cuenta el trabajo tan complejo de este lab consideramos que tuvo un desempeño respetable.

- ¿Qué puede observar de las palabras donde el modelo se ha confundido?

Las palabras que no aparecen con frecuencia en el conjunto de entrenamiento o que aparecen en contextos variados pueden ser difíciles de traducir correctamente para el modelo.

Algunas palabras tienen múltiples significados en función del contexto. Si el contexto no es claro o si la palabra tiene una ambigüedad intrínseca, el modelo podría elegir la traducción incorrecta.

En arquitecturas como el Transformer, el mecanismo de atención decide a qué partes del texto de entrada "prestar atención" al generar una traducción. Si este mecanismo no se enfoca en las partes relevantes del texto, puede llevar a errores en la traducción.

- Observe el comportamiento de la pérdida y PPL en training y validation mientras se entrega el modelo, ¿qué puede decir de estos valores?

Disminución Continua de Pérdida y PPL: Ambas métricas, tanto para entrenamiento como para validación, disminuyen con el tiempo. Esto indica que el modelo está aprendiendo y mejorando su capacidad de predicción en el conjunto de entrenamiento y también está generalizando bien al conjunto de validación.

en el conjunto de entrenamiento y también está generalizando bien al conjunto de validación.

Brecha entre Entrenamiento y Validación: Si bien hay una brecha entre la pérdida y PPL de entrenamiento y validación, esta no es extremadamente grande. Una gran brecha podría haber indicado sobreajuste, donde el modelo se desempeña excepcionalmente bien en el conjunto de entrenamiento pero no tan bien en el conjunto de validación.

Estabilidad al Final: En las últimas épocas, especialmente entre la 8ª y 10ª época, la pérdida y PPL en validación parecen estabilizarse e incluso aumentar ligeramente. Esto podría ser un indicativo de que el modelo está comenzando a sobreajustar o que ha alcanzado un límite en su capacidad para mejorar con los datos actuales y la configuración actual.

PPL Interpretable: La "perplexity" (PPL) indica, en términos generales, cuántas elecciones probablemente está considerando el modelo en cada paso de predicción. Por ejemplo, un PPL de 5 en validación sugiere que el modelo, en promedio, está tan "confundido" al hacer una predicción como si tuviera que elegir uniformemente entre 5 traducciones. A medida que este número disminuye, sugiere que el modelo se vuelve más seguro en sus predicciones.

Convergencia del Modelo: La disminución constante de las métricas seguida de una estabilización sugiere que el modelo está convergiendo. Podría ser útil continuar entrenando durante algunas épocas más para ver si la métrica en validación comienza a aumentar consistentemente, lo que sería un signo claro de sobreajuste.

- Si bien no es una tarea intuitiva o sencilla la interpretación de las gráficas de attention que hemos realizado, intente darle una interpretación a la última de estas gráficas mostrada. ¿Qué tipo de insights podría sacar de esta gráfica?

Correspondencia directa (o casi): Se puede apreciar en la última gráfica que la diagonal que se traza en las palabras generalmente coincide, esto no pasa en todos los casos pero es interesante observar en cuales si sucede. Esto da hints de que vamos por buen camino y de que tal vez al agregar mas eps o mejorar el modelo podamos conseguir resultados más fiables.

In []:

```
print()
print("La fraccion de abajo muestra su rendimiento basado en las partes visibles de este laboratorio")
tick.summarise_marks() #
```